

# Modelado de temperaturas extremas en Uruguay

I. Alvarez-Castro   J. Cugliari   N. da Silva   S. De Mello  
Agustín Estramil   Manuel Hernández   M. Renom

15 de Noviembre de 2019

# orden

Intro:

- ▶ proyecto fsd ( gente, inst, amigos)
- ▶ relevancia y objetivos del proyecto

Datos:

- ▶ origen y problemas en los datos
- ▶ definicion olas (punto, gralizada), percentiles
- ▶ Viz (estatica)

Modelos:

- ▶ GEV
- ▶ DLM: modelo
- ▶ DLM: estimacion

Resultados: mostrar shiny app

# 1. Introducción

# Introducción

## Antecedentes y conformación del equipo

- ▶ 2015 Jornadas de estadística en la Paloma.
- ▶ 2016 Presentación del proyecto I+D de CSIC (no financiado).
- ▶ 2017 Fondo sectorial de investigación a partir de datos.(\$\$ :-) )

# Introducción

## Instituciones involucradas

- ▶ IESTA - Facultad de Ciencias Económicas.
- ▶ DCA (DCAOF) - Facultad de Ciencias.
- ▶ INUMET

# Introducción

## Relevancia del problema

- ▶ Problema regional de series con datos faltantes.
- ▶ Relevancia del estudio de extremos.
- ▶ ...

# Introducción

## Objetivo general

Modelización estadística de las series diarias de temperatura máxima y mínima en varias estaciones meteorológicas en Uruguay.

En base a esos modelos:

- ▶ Reconstruir series diarias.
- ▶ Analizar eventos de olas de frío y calor.

# Modelado de temperaturas extremas en Uruguay


## Objetivos específicos

- ▶ Imputación de datos faltantes.
- ▶ Visualización de series diarias.
- ▶ Definición y caracterización de olas de extremos.
- ▶ Métodos para comparar y evaluar series imputadas.



## 2. Datos de Temperatura máxima y mínima

# Origen y problemas de los datos



Período de análisis: 1950 - 2014

# Control de calidad

- ▶ Control de calidad RClimdex - umbral  $3 \text{ STD} + \text{Variabilidad}$  interdiaria de  $T_x$  y  $T_n$ .
- ▶ Programa para visualizar los errores detectados por RClimDex.
- ▶ Se confeccionó una lista con los datos de todas las estaciones para revisar en el INUMET.

# Olas de extremos

**Ola de frío:** al menos 3 días seguidos con temperaturas mínimas y máximas inferiores a los respectivos percentiles 10 esperados para tales días.

Sucesión de días  $t_1, \dots, t_k$  constituyen una ola de frío de largo  $k$  si:

$$\begin{cases} y_{t_i}^n < p_{10_i}^n \\ y_{t_i}^x < p_{10_i}^x \end{cases} \quad \text{para } i = 1, \dots, k \text{ donde } k \geq 3$$

Se debe verificar al menos 5 de las 6 condiciones anteriores.

# Calcular percentiles

Percentiles para cada día del año:

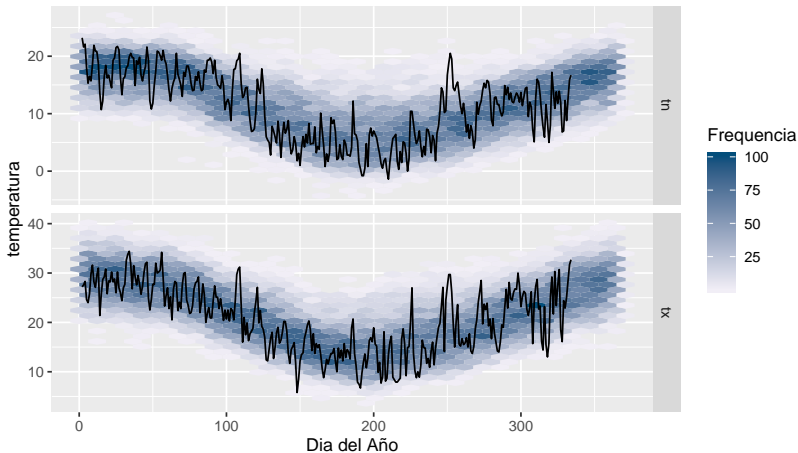
$$p_{10_t}^n := \inf\{y : p(Y_t^n \leq y) \geq 0,1\}$$
$$p_{10_t}^x := \inf\{y : p(Y_t^x \leq y) \geq 0,1\}$$

## Muestral

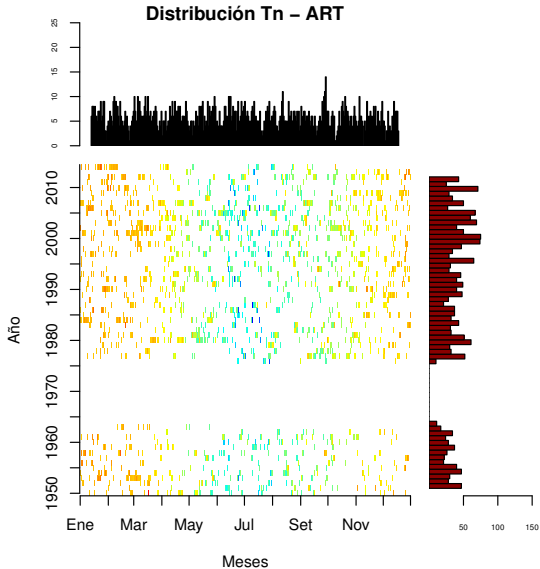
- ▶  $y_{at}$  es la temperatura de día  $t$  en año  $a$
- ▶ cada día  $t$ , calcular cuantiles de  $\{y_{1t}, \dots, y_{At}\}$
- ▶ obtener  $p_{10_t}^n$  como media móvil de ventana 31 (en días)

# Visualizar olas de temperatura


Estanzuela - 2007



# Distribución de datos superando el P90 - ARTIGAS



# Olas de calor - ARTIGAS





# Olas de calor - ARTIGAS



### 3. Modelos estadísticos

# Modelos estadísticos

- ▶  $y_{ti}^n$ : temperatura mínima el día  $t$  en locación  $i$
- ▶  $y_{ti}^x$ : temperatura máxima el día  $t$  en locación  $i$

Imputar las series diarias:

- ▶ Modelos aditivos basados en GEV
- ▶ Modelos Bayesianos diámicos
- ▶ otros: Regresión + ACP, GAM + estructura dependencia, etc

# Modelos estadísticos

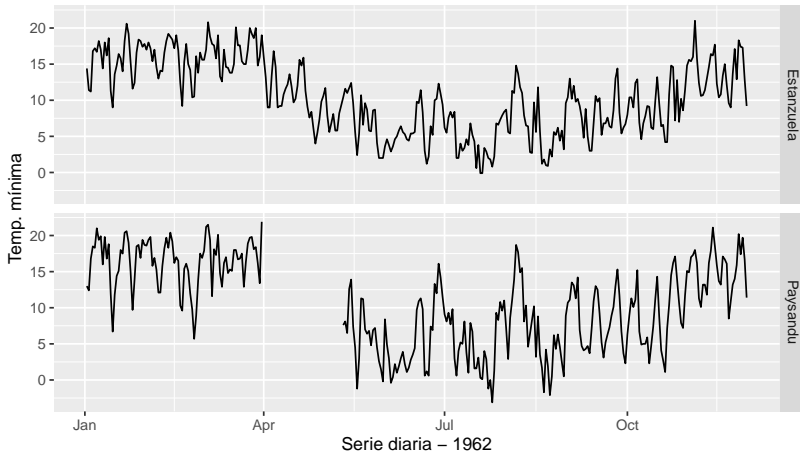
- ▶  $y_{ti}^n$ : temperatura mínima el día  $t$  en locación  $i$
- ▶  $y_{ti}^x$ : temperatura máxima el día  $t$  en locación  $i$

Imputar las series diarias:

- ▶ Modelos aditivos basados en GEV
- ▶ Modelos Bayesianos diámicos
- ▶ otros: Regresión + ACP, GAM + estructura dependencia, etc

# Ejemplo Imputación

En 1962, hay 40 días sin temperatura mínima en Paysandu



# Modelos aditivos basados en GEV


$$G(y_{ti}^x) = \exp \left\{ - \left[ 1 + \xi \left( \frac{y_{ti}^x - \mu_{it}}{\sigma_i} \right) \right]_+^{-1/\xi} \right\}$$

$$\mu_{it} = s(t) + s(mei) + cl_i$$

- ▶ un parámetro de escala por estación,  $\sigma_i$
- ▶ un parámetro de forma,  $\xi$
- ▶ imputamos con la locación:  $\tilde{y}_{ti}^x = \hat{\mu}_{it}$

## Modelo dinámico lineal

$$\begin{aligned} Y_t &= F_t \theta_t + v_t & v_t &\sim \mathcal{N}(0, V_t) \\ \theta_t &= G_t \theta_{t-1} + w_t & w_t &\sim \mathcal{N}(0, W_t) \end{aligned}$$



# DLM para temperatura

- ▶ temperatura observada: real- ruido
- ▶  $\theta_t$  entendido como el valor no observable de la temperatura **sin** ruido
- ▶ dependencia en  $\theta_t$ : de otras estaciones y de si misma
- ▶ NO toma en cuenta caracter extremo

$$\begin{aligned}y_t^n &= \theta_t + v_t & v_t &\sim \mathcal{N}(0, \sigma^2 I_{11}) \\ \theta_t &= \theta_{t-1} + w_t & w_t &\sim \mathcal{N}(0, W)\end{aligned}$$



# Estimación proceso de estados

Inferencia Bayesiana:

$$p(\text{parámetro}|\text{datos}) \propto p(\text{datos}|\text{parámetro}) \times p(\text{parámetro})$$

Inferencia probabilística: conclusiones se basan en una distribución de cantidades de interés *condicional* en los datos.

Dos posteriores relevantes:

- ▶ Filtro:  $p(\theta_t|y_{1:t})$
- ▶ Suavizado:  $p(\theta_t|y_{1:T})$

## Filtro de Kalman: $p(\theta_t|y_{1:t})$

Estimacion recursiva, en base a  $p(\theta_{t-1}|y_{1:(t-1)})$ :

- ▶ Previa:

$$p(\theta_t|y_{1:t-1}) = \int p(\theta_t|\theta_{t-1})p(\theta_{t-1}|y_{1:t-1})d\theta_{t-1}$$


- ▶ Posterior Filtrada:

$$p(\theta_t|y_{1:t}) = \frac{p(y_t|\theta_t)p(\theta_t|y_{1:t-1})}{p(y_t|y_{1:t})} \propto p(y_t|\theta_t)p(\theta_t|y_{1:t-1})$$

- ▶ Previa para estado inicial:  $\theta_0 \sim N(m_0, C_0)$
- ▶ Soluciones cerradas en el caso *gaussiano lineal*

# Ejemplo Imputación

Los metodos para obtener posteriores de  $\theta_t$  no se ven afectados



# Resultados

Aplicacion shiny

Siguientes pasos

- ▶ evaluar efecto de la imputacion en las olas estimadas
- ▶ caracterizar olas

4. Muchas Gracias !!